


KAGGLE PLAYGROUND SERIES S4E4 · 최종 발표

Abalone Regression

RMSLE 최적화와 최종 제출 후보 정리

OOF RMSLE 0.149828 → **0.147529**

[발표자 : 정호림] · [Basic Track 6조]



■ 최종 결과 한눈에

HGBR 한계를 넘어 OOF 0.147대로

최종 OOF RMSLE

0.147529

최종 후보

submission_v5_boosting_ensemble.csv

기존 HGBR best

0.149828

튜닝만으로는 한계

가장 큰 개선

Target Encoding


전환점이 된 구간

Kaggle score

330

현재는 OOF 기준 평가

성능 개선 흐름 · OOF RMSLE



RMSLE에 맞춘 학습 전제 고정

문제 Kaggle Playground S4E4 — Abalone Rings 회귀

입력 크기 · 무게 피쳐 + 범주형 성별

타겟 Rings ($\text{Age} = \text{Rings} + 1.5$)

평가지표 RMSLE — 비율 오차에 민감한 지표

학습 원칙

`log1p(Rings)` 학습 · `expm1` 복원 · `np.clip(pred, 0, None)`

RMSLE 민감도 — 같은 오차 2, 다른 페널티

실제값 2 / 예측값 4

큰 RMSLE 페널티

작은 실제값 구간 — 비율 오차가 큼


실제값 20 / 예측값 22

작은 RMSLE 페널티

큰 실제값 구간 — 비율 오차가 작음

→ **log target** 학습과 음수 **clipping**이 모든 모델의 기본 전제

재현 가능한 디렉토리 흐름



원본 불변

raw 데이터는 수정하지 않음



중간 산출물 재사용

feature / prediction은 proceed에 적재




코드·제출·문서 분리

결과 추적과 재현성 확보

EDA가 만든 모델링 가설

Rings 분포 — 오른쪽 꼬리를 가진 count형 타겟



EDA는 *log target* · *ratio feature* · *target encoding* 후보를 만들었다.


모델링으로 이어진 관찰

- 1 결측치 · 중복 없음 → 정제 비용 낮음
- 2 Rings는 오른쪽 꼬리 → log target 학습
- 3 Shell_weight · Height · Diameter 등 강한 신호
- 4 Sex별 분포 차이 → one-hot + target encoding
- 5 train/test drift 작음, 모델 선택엔 test 미사용

검증 설계

작은 개선을 해석 가능하게 만드는 틀

5-fold StratifiedKFold (Rings quantile bin 기준)



train split ■ validation split

test set

모델 선택에 미사용 — drift 확인과
최종 예측에만 사용

모델 선택 기준

CV RMSLE mean / std + OOF RMSLE

fold 내부 통계만 적용

validation에는 train 통계를 적용만

target encoding 분리

누수 위험 → 별도 OOF-safe 구현

01부터 08까지, 질문 단위의 노트북




01-05 기본 파이프라인

06-08 최종 성능 개선 라인

■ BASELINE

출발점: 같은 fold, 같은 RMSLE로 비교

CV RMSLE mean · 6개 모델 비교 (Dummy median 제외)



best baseline

**HistGradientBoosting
+ log target**

OOF RMSLE **0.149919**

CV RMSLE mean **0.149917**


CV RMSLE std **0.000889**

이후 모든 개선의 기준선이 되는 값

HGBR 튜닝의 한계

feature-tuning 개선폭은 약 0.0001

HGBR modeling 후보 · CV RMSLE mean



v1 feature

17개 피쳐

v2 feature

39개 — shape ratio · log 피쳐 추가

best · v2_hgb_log_leaf45_clip

OOF RMSLE **0.149828**


baseline 대비 개선폭 ≈ 0.0001

CV std ≈ 0.0009 — 이 방향만으로는 큰 전환이 어렵다고 판단
, Target Encoding으로 방향 전환

■ 전환점 · 가장 큰 성능 개선 구간


Target Encoding

v2_hgb_log_leaf45_clip



0.149828

v2_lgbm_log



0.149206

v2_te_lgbm_log



0.147765

+ target encoding

추가된 target encoding 피쳐

- Sweight_avg
- Height_avg
- Weight_avg
- Viscera_weight_avg
- Sex_avg


LGBM + log target

0.147765

HGBR best 대비 -0.002063

Fold-safe Target Encoding

학습 / 검증 경로




test 예측

전체 train으로 mapping refit → test에 적용 · 미매칭 값은 fallback mean 처리

→ fold train split만으로 mapping을 만들어 validation target 정보가 통계에 섞이지 않게 분리

■ 외부 데이터 결합

UCI Abalone 원본으로 학습 보강




OOF RMSLE **0.147607**

외부 데이터는 fold train에만 추가 — 개선폭 ≈ 0.00016 , 작지만 데이터 보강 효과

BOOSTING ENSEMBLE

단일 모델보다 낮은 OOF를 만든 단순 평균

단일 모델 vs 1:1:1 앙상블 · OOF RMSLE



최종 후보 · equal_linear

0.147529

LGBM · XGBoost · CatBoost 단순 평균

equal_linear	0.147529
--------------	----------

equal_log	0.147530
-----------	----------

최종 제출	submission_v5
-------	---------------

log 평균도 거의 동일 — 가중치 튜닝보다 모델 다양성이 핵심.

■ 전체 성능 개선 흐름

피처와 검증 설계가 모델 선택만큼 중요했다



단계별 OOF RMSLE

Baseline	0.149919
HGBR tuning	0.149828
Target Encoding	0.147765
External Data	0.147607
Ensemble	0.147529
0.149919 → 0.147529	

■ 결론 · CONCLUSION

핵심 메시지와 다음 작업

01

RMSLE에 맞춘 전제

log target 학습 + 음수 clipping을 모든 모델에 유지

02

OOF-safe 검증

fold·metric·OOF 기준 고정으로 작은 개선을 해석

03

Target Encoding

HGBR 튜닝이 아닌 fold-safe TE가 핵심 전환점

다음 작업

- public / private score 기록
- TE smoothing · Optuna 튜닝
- tail calibration — CV와 LB gap 동시 점검

Q & A

최종 OOF RMSLE **0.147529**