



CUAI 3팀

2026.05.26

발표자: 서민서, 이규성
(김세현, 방정원)

제조공정 불량 예측 파이프라인

공정 센서 데이터로 이상 가능성을 먼저 선별하고, 고장 여부와 고장 유형을 단계적으로 예측하는 구조 설계

최종 구현 파이프라인



① 1차 필터

비지도 이상탐색(OCSVM+LOF)으로 확실한 정상 데이터를 먼저 제거

② 모델 1

필터링된 데이터에서 고장 여부를 이진 분류

③ 모델 2

고장으로 판단된 경우 고장 유형을 다중 분류

1차 필터 개요



1차 필터 — 비지도 이상탐지 앙상블

모델	판단 기준	역할
OCSVM	정상 경계 밖	전체 분포에서 벗어난 데이터 탐지
LOF	주변 밀도 차이	주변 대비 이질적인 데이터 탐지
OR	둘 중 하나라도 이상	고장 가능 데이터 최대한 통과

OCSVM 또는 LOF 중 하나라도 이상으로 판단하면 통과

1차 필터 결과

원본 데이터	10,000개
필터 후 데이터	5,598개
제거 데이터	4,402개
전체 고장 데이터	339개
유지된 고장 데이터	319개
고장 Recall 유지율	94.1%

44%
데이터 제거


94.1%
고장 유지

정상 가능성이 높은 샘플을 일부 제거하고, 고장 가능성이 있는 데이터를 모델 1,2로 전달

문제점 1. 비지도 이상탐지 성능의 한계

① 1차 필터만으로 고장 판단이 가능한가?

기존 목표



기존 시도	실제 결과	목표 변경
비지도 이상탐지 적용 정상/이상 데이터 분리 이상 데이터만 후속 모델 전달	이상탐지 성능 저조 정상·고장 데이터 혼재 고장 후보의 정확한 추출 어려움	완벽한 이상탐지보다 고장 데이터 손실 최소화 Recall 중심 데이터 선별

1차 필터 역할: 고장 데이터 보존 + 정상 가능 데이터 일부 제거 → df_filtered 생성 후 모델 1.2 전달

모델 1·2 개요



모델 1 — 고장 여부 이진 분류

Logistic Reg.	P	R	F1
	0.226	0.825	0.354
Random Forest	P	R	F1
F1 1위	0.697	0.862	0.770
Gradient Boosting	P	R	F1
최종 선택	0.482	0.915	0.630
Decision Tree	P	R	F1
	0.395	0.919	0.551

모델 2 — 고장 유형 다중 분류

Logistic Reg.	P	R	F1
F1 1위	0.977	0.972	0.972
Random Forest	P	R	F1
최종 선택	0.970	0.965	0.966
Gradient Boosting	P	R	F1
	0.968	0.959	0.964
Decision Tree	P	R	F1
	0.941	0.938	0.939

문제점 1. 모델 선정 과정(모델1)

① 어떤 지표를 기준으로 모델을 선택해야 하는가?

False Negative (미탐)

실제 고장인데 정상으로 예측

설비 파손 · 라인 중단 · 안전사고

→ Recall이 낮으면 이 실수가 많아짐

VS

False Positive (오탐)

실제 정상인데 고장으로 예측

불필요한 점검 비용 (상대적으로 작음)

모델별 Precision · Recall · F1

모델	P	Recall	F1	
Gradient Boosting	0.48 2	0.915	0.630	← 선택
Decision Tree	0.39 5	0.919	0.551	
Random Forest	0.69 7	0.862	0.770	
Logistic Reg.	0.22 6	0.825	0.354	

Recall 우선 → GB 선택

Recall 0.915(DT와 동급)이면서
Precision이 더 높아 오탐을 줄인 균형점

문제점 1. 모델 선정 과정(모델2)

② F1이 높다고 좋은 모델인가?

모델 2 평가 결과		
모델	F1	Std
Logistic Reg. F1 1위	0.972	0.022
Random Forest 최종 선택	0.966	0.009
Std ↑ 불안정 ↔ Std ↓ 안정		

문제점 2. 정답 데이터 부족

모델 1 — 고장 여부

전체 5,598개 중 고장: 319개 (5.7%)

모델이 항상 '정상'으로만 찍어도
Accuracy 94%가 나옵니다.

→ 고장 패턴을 아예 학습하지 못하는 문제



5-Fold 기준 Validation fold당 고장 샘플: 약 64개


→ 수치가 fold마다 흔들릴 수 있음

모델 2 — 고장 유형

고장 데이터 290개만 사용

고장 유형별 샘플 수 편차 극심
5-Fold 시 fold당 일부 유형은 10개 미만

→ 검증 수치 자체가 신뢰하기 어려움



문제점2. 해결책 — SMOTE + K-Fold

SMOTE란?

소수 클래스(고장) 샘플들 사이를 보간하여 합성 샘플을 생성합니다. 학습 데이터의 클래스 불균형을 해소하는 데 사용합니다.

✗ 잘못된 순서

전체 데이터에 SMOTE 적용

K-Fold 로 분리

학습 → 평가

합성 샘플이 Validation에 섞임
→ 성능이 과대평가됨

✓ 올바른 순서

K-Fold 로 먼저 분리

Train fold에만 SMOTE

Validation은 원본 그대로 평가

Validation = 실제 데이터만
→ 검증 수치를 신뢰할 수 있음

문제점2. 보완책 — RepeatedStratifiedKFold

문제: Validation fold당 고장 샘플이 ~64개 (모델1) / ~10개 미만 (모델2) → 수치가 fold마다 흔들림

항목	StratifiedKFold(5)	RepeatedStratifiedKFold(3×5)
총 검증 횟수	5회	15회
fold당 Train 비율	80%	67%
결과 분산	높음	낮음 (안정)
극소 클래스 적합성	불안정	안정
현실적 한계 (모델 1): RAM 5GB 환경에서 RepeatedKFold는 메모리 초과로 실행 불가 → 5-Fold 유지, 대신 Std(표준편차)가 낮게 나와 수치를 어느 정도 신뢰할 수 있다고 판단 → 모델 2에는 RepeatedStratifiedKFold(3×5) 적용 완료		

결론 — 전체 모델이 가지는 의미

01

비지도 + 지도 결합형 2단계 파이프라인의 완성

OCSVM + LOF 비지도 앙상블로 56%의
정상을 선제 필터링하여 데이터 효율성을
극대화하고, 이진 분류(고장 여부)와 다중
분류(고장 유형)를 직렬로 연결한 제조 맞춤형
아키텍처 구현.

02

철저한 데이터 격리를 통한 검증 신뢰성 확보

Train fold 내에서만 SMOTE를 수행하는
엄격한 순서를 고수하여, 합성 데이터가
Validation fold에 누출되는 '데이터
누수(Data Leakage)와 성능 과대평가'를
원천 차단.



감사합니다

THANK YOU