

CUAI 스터디 8조

2026.05.27

발표자 : 박상현, 박수현, 엄지용, 주찬진

스터디원 소개 및 만남 인 증

스터디원 1 : 박상현

스터디원 2 : 박수현

스터디원 3 : 엄지용

스터디원 4 : 주찬진

머신러닝으로 검증하는 통계의 진실

과연 근로자의 임금보다 세금이 더 많이 증가 했을까?

발표자 : 박상현

공모전 수상자 오지용의 인사이드



기사의 주장

"지난 10년간 월급 21% 오를 때 세금 75% 폭증했다"며 보편적 근로자의 고통을 강조.



결정적 오류 (생존자 편향)

면세자를 제외한 '과세자' 연봉만 추출하여 중저소득층의 데이터를 통계에서 삭제.



누진세 구조 간과

중산층 이하 세율은 동결되었으나, 고소득층의 세율 인상분을 전체의 부담인 것처럼 왜곡.



본 분석의 목표

이 비판적 직관을 머신러닝 기술로 입증하고 조세 정책의 숨겨진 모순을 발굴함.

데이터 소개

활용 데이터셋	출처 기관	조사 기간	핵심 피처 (Features)
근로소득 연말정산 신고현황	국세통계포털 (TASIS)	2012 ~ 2024	과세표준 구간별 인원, 급여, 결정세액
소비자물가지수 (CPI)	국가통계포털 (KOSIS)	2012 ~ 2024	연도별 물가 가중치 (실질가치 변환용)
연도별 소득세율 규칙	국가법령정보센터	2012 ~ 2024	누진세율(6%~45%), 공제 한도 규칙(Rule)

* 총 167개 마이크로 집계 레코드를 활용하여 시계열 및 비지도학습 분석 수행

데이터 특징 및 전처리 파이프라인

■ 데이터 특징

- 13년간 시계열 (2012~2024)
- 과세표준 구간별 집계 데이터
- 면세자 포함 전체 근로자
- 주요 변수: 인원량,
- 총급여량, 결정세액

원천 데이터

KOSIS 근로소득세 신고현황,
소비자물가지수(CPI) 등

■ 전처리 6단계 (Python / pandas)

01

수집 & 인코딩 처리

KOSIS CSV를 cp949로 로드, 한글 깨짐 방지

02

결측치 정제

KOSIS 특수기호('-')를 NaN → 0 으로 변환 (coerce)

03

구조 재편 & 단위 통일

Pivot으로 항목별 정렬, 금액 백만원→원 환산

04

파생 변수 생성

1인당 평균급여세액, 실효세율(%) 산출

05

실질 가치 변환

CPI 병합 후 실질임금 = (명목 ÷ CPI) × 100

06

도메인 지식 & 표준화

연도별 누진세율 매핑 + StandardScaler 표준화

머신러닝 분석 설계

두 개의 모델로 기사의 주장을 교차 검증했습니다.

모델 1. Random Forest Regressor

지도학습 회귀 — 세금 결정 원리 학습

입력(X)

시점, 실질 1인당 평균급여, 법정 한계세율

출력(y)

실질 1인당 평균 세액

평가

R^2 Score 로 예측력 측정

핵심

Feature Importance로 세금 증가의 핵심
요인 도출

모델 2. K-Means Clustering

비지도학습 군집화 — 계층 자동 분류

입력(X)

임금 증가율, 세금 증가율 (2012→2024)

전처리

StandardScaler 표준화로 단위 차이 제거

설정

n_clusters = 2 — 두 개의 그룹으로 분류

결과


일반 근로자 vs 고소득 이상치 그룹

※ 트리(Tree) 기반 모델이 누진세의 '계단식 구조'를 학습하는 데 가장 적합


THOAI

분석 결과 (1) — 머신러닝 가설 검증

공모전 수상자(오지용)의 가설, 머신러닝으로 검증하다




지난 13년간 국가 전체 세금 증가분(총액) 기여도



핵심 발견: 작성자 가설은 사실이었다

AI 군집화 결과 일반 근로자와 고소득층이 명확히 분리되었으며,
기사 주장 평균(75%) 근처에는 실제 데이터가 존재하지 않습니다.

분석 결과 (2) — 누진세의 진실



▲ 세금 폭증은 고소득층 구간(빨간)에서만 집중 발생

세율 동결의 명암

서민/중산층

13년간 법정 세율 변화 0%, 실효세율은 오히려 하락.

고소득층

최고세율 38%→45% 인상 구간에서만 세부담 급증.

기사의 평균 수치는 세율 변화가 없는 대다수 근로자의 실제 세부담을 대변하지 못하는 통계적 왜곡.

분석결과 vs 인사이트 비교 → 결론

분석 관점	수상자 오지용의 인사이트	CUAI 8조 AI 검증 결과
데이터 대표성	과세자만 추출하여 평균 왜곡	면세자 복원 시 실제 세부담 완화 확인
세금 증가 요인	고소득층의 소득 상승 및 세율 인상	소수 고소득층이 세수 증가분의 절반(48.6%) 부담
보이지 않는 증세	—	공제 한도 동결로 과세표준 폭주 포착
최종 평가	기사는 통계 조작 수준의 착시	“가짜 평균”임이 수학적으로 증명됨

결론: 세금 폭발은 통계적 착시였다

기사는 면세자를 배제한 생존자 편향으로 평균을 왜곡했으며, AI는 세금 폭증의 불평등한 실체를 수학적으로 입증했습니다.

인공지능으로 바라본 대한민국 지역별 항생제 사용량

발표자 : 박수현

공모전에서 제시한 인사이트

1. 수상작 내용 요약

출품자: 정혜원 (워싱턴대학교 심리학과)

사례명: OECD 국가내 한국의 항생제 사용량 통계의 왜곡 해석된 활용

배경: 국내 언론들은 2016년 OECD 보고서를 인용하며, "한국의 항생제 하루 사용량(31.5DDD)이 OECD 최고 수준이며 스웨덴의 2배가 넘는다"며 보건학적 위기가 온 것처럼 보도

2. 수상작에서 나온 결론

1) 국가마다 완전히 상이한 통계 범위

국가별로 병원 데이터와 상환 의약품 포함 여부가 달라, 병원·의원 데이터를 모두 제출한 한국의 수치가 상대적으로 높게 나타날 수 있었다.

2) 데이터 제출 및 조사 방식의 불일치

유럽 국가들은 표준화된 공통 데이터베이스를 활용한 반면, 일부 국가는 자체 데이터를 직접 제출해 국가 간 통계 기준의 일관성이 부족했다.

3) 국내 실제 트렌드와의 모순 무시

건강보험심사평가원 자료에서는 항생제 처방률이 감소 추세였지만, 언론은 국제 비교 지표만을 근거로 사용량이 급증한 것처럼 보도했다.

공모전에서 제시한 인사이트

JAMA
Network | Open.



Original Investigation | Environmental Health

Short-Term Exposure to Ambient Air Pollution and Antimicrobial Use for Acute Respiratory Symptoms

Gabriela Abelenda-Alonso, MD, PhD; Pau Satorra, MSc; Marc Mari-Dell'Omo, MSc, PhD; Cristian Tebé, PhD; Ariadna Padullés, PhD; Andrea Vergara, PhD; Carlota Gudol, MD, PhD; Miquel Pujol, MD, PhD; Jordi Carratalà, MD, PhD

Abstract

IMPORTANCE Ambient air pollution and antimicrobial resistance pose significant global public health challenges. It is not known whether ambient air pollution is associated with increased consumption of antimicrobials.

OBJECTIVE To assess whether a short-term association exists between ambient air pollution levels and antimicrobial consumption among the general population seeking primary care consultations for acute respiratory symptoms.

DESIGN, SETTING, AND PARTICIPANTS This 2-stage cross-sectional ecological time series analysis study using data on daily ambient air pollution and antimicrobial consumption was conducted in the 11 largest cities in Catalonia, Spain, from June 23, 2012, to December 31, 2019, among all inhabitants aged 12 years or older. Statistical analysis was performed from November 2022 to December 2023.

EXPOSURES Daily ambient air pollution (particulate matter of 10 $\mu\text{g}/\text{m}^3$ [PM_{10}], particulate matter of 2.5 $\mu\text{g}/\text{m}^3$ [$\text{PM}_{2.5}$], and nitrogen dioxide [NO_2]).

MAIN OUTCOMES AND MEASURES The main outcome was antimicrobial consumption associated with primary care consultations for acute respiratory symptoms in the 30 days before and after the dispensing of the antimicrobial. Antimicrobial consumption was measured as defined daily doses (DDDs) per 1000 inhabitants per day.

RESULTS Among 1 938 333 inhabitants (median age, 48 years [IQR, 34–65 years]; 55% female participants), there were 8 421 404 antimicrobial dispensations, with a median of 12.26 DDDs per 1000 inhabitants per day (IQR, 6.03–15.32 DDDs per 1000 inhabitants per day). The median adjusted

Key Points

Question Are short-term exposures to ambient air pollution associated with an increase in antimicrobial use among individuals seeking primary care for acute respiratory symptoms?

Findings In this 2-stage cross-sectional study using ecological time series analysis, increases in particulate matter of 10 $\mu\text{g}/\text{m}^3$, particulate matter of 2.5 $\mu\text{g}/\text{m}^3$, and nitrogen dioxide concentrations were associated with increased antimicrobial consumption on the day of exposure, with a delayed association observed for $\text{PM}_{2.5}$ between days 7 and 10 after exposure.

Meaning These findings suggest that ambient air pollution is associated with increased antimicrobial use for acute respiratory symptoms and underscore the need for more ambitious policies to reduce pollution exposure on a global scale.

핵심 연구 결과

1 대기오염 증가와 항생제 사용량 증가

- 연구 결과, 초미세먼지($\text{PM}_{2.5}$), 미세먼지(PM_{10}), 이산화질소(NO_2) 농도가 증가한 날에는 급성 호흡기 증상 관련 항생제 사용량도 함께 증가하는 경향이 확인되었다.

2 대기오염의 호흡기 건강 영향

- 연구진은 대기오염이 호흡기 건강 악화와 의료 이용 증가를 통해 항생제 사용 증가에 영향을 줄 수 있다고 설명하였다.

3 초미세먼지의 지연 효과 확인

- 특히 초미세먼지($\text{PM}_{2.5}$)는 노출 당일뿐 아니라, 노출 후 7~10일이 지난 시점까지도 항생제 사용량 증가와 연관되는 지연 효과가 나타났다.

Source: Gabriel Abelenda-Alonso et al., “Short-Term Exposure to Ambient Air Pollution and Antimicrobial Use for Acute Respiratory Symptoms,” *JAMA Network Open* (2024)

공모전에서 제시한 인사이트

기존 수상작이 지적한 “국가 간 비교 왜곡” 논리를 국내로 확장해, 같은 수집체계에서도 외부요인(초미세먼지, 연령구조 등)을 고려하지 않으면 결과가 왜곡될 수 있다는 점을 머신러닝으로 보였다.

문제의식

기존 연구 vs 본 연구

국가 간 통계
기준이 달라
단순 비교가
위험함

국내는 기준이 같아도
지역 조건이 달라 단순
총량 비교가 위험할 수
있음

연구 주제

"지역별 항생제 소비 격차는 오남용의
결과인가, 환경·인구 구조적 취약성에
따른 필연적 수요인가?"

연구 설계

대상: 2024년 전국 시군구
종속변수: 지표값(1일사용량_1천명당)
독립변수: 평균_초미세먼지, 0~4세 인구,
65세 이상 인구

RandomForest

단일 모델의 과적합을 방지하고,
보건·환경 데이터의 비선형적
상호작용을 정밀하게 포착하여 예측
신뢰도를 극대화하기 위해 사용




데이터 소개 및 전처리 과정

데이터명	출처	사용한 데이터
국민건강보험공단_지역별 항생제사용량	공공데이터포털 (2024년도 자료 사용)	연도별 질병에 따른 항생제 종류별 사용량을 산출한 데이터 (대상: 해당 연도 기준 국민건강보험 가입자 또는 의료급여 수급권자)
한국환경공단_에어코리아 _최종확정 측정자료	공공데이터포털 (2024년도 자료 사용)	시군구별 초미세먼지(PM25) 데이터
행정구역(시군구)별 주민등록인구(5세별)	행정안전부 주민등록 인구통계 (2024년도 자료 사용)	데이터 0~4세, 65세 이상 인구 데이터

전처리 과정


항생제 데이터를 기준으로 시군구별 초미세먼지 및 전연령 인구 데이터를 결합하고,
초미세먼지 결측치는 해당 시·도 평균값으로 보정

데이터 특징 - 각 데이터를 단순히 시각화한 그래프




분석 결과

분석 1: 외부 요인(환경·인구)에 따른 항생제 처방량의 높은 연동성



분석 2: 환경 악화 및 면적 취약 인구 밀집으로 항생제 수요가 급증하는 상위 지역



- 미세먼지와 연령 구조만으로 학습된 모델의 예측치(x)가 실제 지자체별 항생제 사용량(y)과 $y=x$ 대각선상에서 유사한 경향을 보임
- 단편적인 지표 비교로는 보이지 않던 초미세먼지와 인구 구조의 복합적인 상호작용이 실제 항생제 처방량을 결정짓는 원인임을 머신러닝으로 확인
- 지역별 항생제 소비량 격차는 의사들의 무분별한 오남용이 아니라, 지자체별로 처한 환경적·구조적 요인에 의한 실제 의료 수요가 반영된 결과

지역별 항생제 사용량은 초미세먼지 수준과 연령구조(영유아, 고령인구)로 상당 부분 설명되었으며, 일부 고사용 지역은 오남용보다 실제 의료 수요가 반영된 결과일 가능성이 확인되었다.

항생제 관리정책은 단순 사용량 비교가 아닌, 외부요인을 고려한 예측값 대비 차이를 기준으로 이루어질 필요가 있다.

B a s i c 8 p r o j e c t

세계 성격차지수는 정말 '성평등'을 재는가?

순위의 착시를 144개국 전수 + ML을 통한 검증

CUAI 9기 Basic 8조 발표자: 엄지용

수상작 — 세계 성격차 보고서의 왜곡·확대 해석

노정훈·오주상 (세종과학예술영재 학교)

연합뉴스 "한국 양성평등 세계 115위" 보도 비판 — GGI는 성'격차'지수인데 성'평등'지수로 확대해석됨

- 1 점수 산출 (여/남) 비율을 1에서 잘라내 여성 우세 영역도 무시
- 2 항목 부적절 출생성비·경제활동참가율은 성평등 지표로 부적절
- 3 비율 계산 한국·르완다가 동일 점수 — 발전 수준 무시
- 4 단순평균의 함정 교육·건강은 분산이 없어 평균에 넣어도 무의미
- 5 순위 확대해석 만점 근처의 미세 차이가 큰 순위 차이를 만들


→ 모두 '정성적 직관'. 2015 보고서 144개국을 머신러닝으로 검증.

WEF 세계 성격차지수 (GGGI)

데이터셋	WEF Global Gender Gap Index (종합 + 4개 하위지수)
출처	QoG Standard Time-Series (예테보리대) · 원자료 World Economic Forum
기간	2005 ~ 2023 (메인 : 2015 · 보조 : 2023)
분석 단위	2015년 144개국 × 4개 하위지수
하위 지수	경제참여 · 교육 · 건강 · 정치참여

검증 포인트 한국 2015 = 종합 0.649 · 116위. 수상작이 인용한 값과 동일
→ 같은 보고서, 2개국 사례를 144개국 전수로 확장.

4영역의 분산이 극단적으로 다르다



01

컬럼 선택

종합 + 4개 하위지수(gggi_*) 추출

02

결측 제거

4지수 모두 보유한 144개국 정제

03

연도 분리

2015 메인 / 2023 보조 분할

04



표준화

StandardScaler (PCA·군집용)

변동계수(CV) 건강 1.0% · 교육 7.3% (거의 안 변함) vs 경제 18.7% · 정치 68.2% (넓게 분포)

분석 결과 ①



지수는 사실상 '2차원'이다



정치 + 경제 = 변수중요도 88.7% · PC1+PC2 = 분산 87.5%
→ 교육·건강은 정보를 거의 주지 않는다 (비판 ④ 입증)

분석 결과 ②


순위는 '착시'다



건강 106개국이 86계단에 압축 · 한국·르완다는 교육·건강 동일·경제·정치만 달라 116위 vs 5위 (비판 ③⑤ 입증)

순위는 성평등이 아니라 '합산 방식의 결과'

수상작이 제시한 직관	ML 검증 결과
교육·건강은 평균에 무의미	RF 변수중요도 88.7% = 정치·경제
미세 차이가 순위를 왜곡	건강 106개국이 86계단에 압축
한국·르완다 비교 모순	K- Means 서로 다른 군집으로 분리
편차기반 재지수화 '제안' (미 실행)	실제 적용 → 한국 116위 → 104위




결론 '115위'는 성평등 수준이 아니라 지수 설계의 산물. 2023에도 정치·경제가 95%를 좌우 → 시점이 아닌 '구조'의 문제.

사례 1. 남녀 임금격차의 숨겨진 진실

- (성별) 남자의 평균소득은 390만원, 중위소득은 300만원이며, 여자의 평균소득은 236만원, 중위소득은 179만원임



<성별 소득구간 분포>



수상작에서 제시하는 인사이트

단순 평균/중위값 비교는 타당하지 않음: 교란변수의 누락

- 경제활동 인구수: 남성(75%) > 여성(57%)
- Outlier(연봉 1억 5천 이상)의 90%가 남성
- 교란변수: 근무시간, 초과근무, 근속 등



활용 데이터 (N = 18)

데이터	출처	주요내용
성별 임금	고용노동부	26년 1~2월 산업/규모별 임금 및 근로시간
성별 임금	고용노동부	2025 산업,근속년수,성별 임금 및 근로조건
성별 비경제활동 인구	국가데이터 처	성별 비경제활동인구 2026

데이터 전처리/프로세스



Normalization

연령, 근속연수 등 연속형 변수를 StandardScaler로 정규화



Target 정제

총임금이 아닌 노동시간이 보정된 '시간당 임금'을 종속변수로 설정



Binomial Encoding

성별 및 직종 데이터를 이진수 기반 비트 컬럼으로 수치화


N=18

LOOCV/Lasso

소규모 데이터 overfitting 방지


분석 결과

Feature Importance(Ridge)




분석 결과

Feature Importance(Tree Regression)



분석 결과

남성/여성 초과근무 비교



'근속 년수' → 임금을 결정하는 가장 중요한 요소.
하지만, '남성'이 임금에 끼치는 영향도 무시할 수는 없음.

결론

공모전의 직관적 주장

교란 변수가 격차를 유발한다

성별 자체의 영향은 작다

평균 소득 비교는 부적절하다

ML Audit 결과

입증 (Ridge Coefficients 근속연수 압도적 1위)

결코 무시할 수 없는 수준

입증 (LOOCV를 통해 N=18에서도 안정적 모델 확보)

임금에서 여성 차별이 일어나는 것이 아닌,
노동 시장에 여성의 특성이 반영된 결과

결론

“

여성이 **결혼 및 출산**에 따른 경력단절 및 불이익을 야기하는 연공서열 방식의 승진과 임금체계와 같은 직장문화 및 **사회적 제도의 개선**이 선행되어야 함.

”